

Aleksejs Buss

AI ENGINEER · MULTI-AGENTEN-SYSTEME

*Schöpfer von Orchestra — Open-Source-Mixture-of-Agents-Plattform.
Acht Produktionssysteme. Solo ausgeliefert.*

E-MAIL	aleksbuss@gmail.com
GITHUB	github.com/aleksbuss
LINKEDIN	linkedin.com/in/aleksejs-buss
WEB	aleksejs-portfolio.pages.dev
STANDORT	Hof / Saale, DE · EU-Bürger
STATUS	Sofort verfügbar · remote oder vor Ort

§ 01 Profil — *auf einen Blick*

AI Engineer mit Schwerpunkt *Multi-Agenten-LLM-Systeme*. Schöpfer von **Orchestra** — einem Open-Source-Mixture-of-Agents-Workspace (TypeScript / Next.js 15) mit **2.602 Tests und 74 dokumentierten Post-Mortems**: parallele Experten-Agenten, ein code-garantierter Skeptiker, Embedding-basierte Disagreement Detection. Seit Mitte 2025 habe ich **acht produktive KI-Systeme** mit echten Nutzern ausgeliefert — Cloudflare Workers (Edge), Telegram Mini-Apps, Multi-Provider-LLM-Pipelines, Zahlungssysteme, Security. Features von der Spezifikation bis zur Live-Infrastruktur, End-to-End — unternehmerische Verantwortung in einer Person.

05/2026 — heute

FLAGGSCHIFF · OSS

Orchestra — *Multi-Agenten-KI-Workspace*

Mixture-of-Agents-Pipeline · code-garantierter Skeptiker · Live-Kosten-Telemetrie.

Self-hosted KI-Workspace, der bei jeder substanziellen Anfrage 3–5 spezialisierte Experten-Agenten parallel ausführt. Router mit dynamischer Persona-Generierung; ein Skeptiker, der per Code — nicht per Prompt — garantiert ist; Embedding-basierte Disagreement Detection, die Expertenkonflikte sichtbar macht statt sie zu glätten; Reflexions-Kritiker + Revisor-Pass. Live-Kostenanzeige (Tokens + USD) pro Chat. BYOK oder vollständig lokal via Ollama. 2.602 Tests, 74 dokumentierte Post-Mortems, CI — MIT-lizenziert.

Router (DPG) → proposers | Skeptic → disagreement detector → Aggregator → reflection

github.com/aleksbuss/orchestra →

Stack: TypeScript (strict) · Next.js 15 · Vitest · Playwright · Docker

08/2025 — heute

PRODUKTION

AI Dictaphone *v7.0*

Edge-Voice-Pipeline · Whisper → LLM · Sub-Sekunden-Latenz.

Serverlose Voice-to-Insight-Pipeline auf Cloudflare Edge. Sprachnachricht → Groq-Whisper-Transkription → LLaMA-3.3-70B-Zusammenfassung → Mini-App-UI. Null Cold-Start, HMAC-verifizierte Webhooks, keine dauerhafte Speicherung von Sprachinhalten.

Telegram Mini-App → Cloudflare Workers → Groq Whisper+LLaMA 3.3 70B

Stack: Cloudflare Workers · Groq Whisper-large-v3 · LLaMA 3.3 70B · JS ESM

09/2025 — heute

AI Moderation *Bot*

n8n-Workflow · Dual-KI-Failover · Auto-Eskalation.

Eine n8n-Pipeline mit 15+ Knoten klassifiziert jede Telegram-Nachricht mit strukturierten JSON-Outputs, leitet zur Aktion weiter und eskaliert Sanktionen über drei Stufen. Dual-Provider-Failover (Nemotron primär, GPT-4.1 als Fallback) hält die Moderation am Laufen, wenn eine LLM-API ausfällt.

Message → Nemotron → fallback GPT-4.1 → Router → action

Stack: n8n · OpenRouter · GPT-4.1-mini · Nemotron · Telegram Bot API

10/2025 — heute

SAAS-PRODUKT

AI Psychology *Bot*

Komplettes SaaS · Zahlungen · Krisenhilfe · CBT-Übungen.

End-to-End-SaaS solo: HMAC-SHA256-Auth → verteiltes Apps-Script-Backend → Firebase Realtime DB → Gemini-2.5- + TTS-Pipeline. Telegram Stars als nativer Checkout, atomare Kredit-Operationen, Referral-Programm, Panik-Intervention, 7-Skill-Protokoll.

Mini-App → HMAC-SHA256 → Apps Script → Firebase → Gemini+TTS

Stack: Gemini 2.5 · Telegram Stars · Firebase RTDB · Apps Script · HMAC-SHA256

02/2025 — heute

BUSHMARK.CC

Bushmark — *Secure Clipboard*

Self-hosted · Cookie-Auth · 1-Klick-Installation.

Selbst gehostete sichere Zwischenablage auf bushmark.cc — drei persistente Slots, 24h-Verlauf, Auto-Rotation, Tailwind-UI. Ein-Zeilen-Bash-Installation auf jedem Ubuntu-VPS richtet Nginx + FastAPI + systemd automatisch ein.

Browser → Nginx reverse proxy → FastAPI (systemd)

bushmark.cc → Stack: FastAPI · Nginx · systemd · Tailwind · Ubuntu 24.04

07/2025 – heute

SELF-HOSTED

CyberDed Ultra + ComfyUI

Lokale KI-Infrastruktur · 1-Klick-Installer · Android + Linux.

Bash-Installer für den gesamten Local-AI-Stack: Ollama für Inferenz, ComfyUI für Bildgenerierung, automatische NVIDIA-Container-Toolkit-Konfiguration, Flask-Backend mit Server-Sent-Events-Streaming-Chat, Echtzeit-Monitoring. Zwei Zielsysteme — Linux + Termux Android.

Bash installer → Ollama+ComfyUI Docker → Flask SSE

github.com/aleksbuss → Stack: Docker · Ollama · Flask · ComfyUI · NVIDIA Container Toolkit

11/2025 – heute

OPEN SOURCE

Termux AI Dictaphone

Android als Offline-KI-Server · null Cloud-Kosten.

Komplette Offline-KI auf jedem modernen Android: Whisper-Transkription via faster-whisper / whisper.cpp, LLaMA-/Gemma-Inferenz via Ollama — alles on-device über Termux. Null API-Kosten, volle Privatsphäre. Als Open Source veröffentlicht.

Termux (Android) → faster-whisper → Ollama (LLaMA, Gemma)

github.com/aleksbuss → Stack: Termux · faster-whisper · whisper.cpp · Ollama · Python

07/2025 — heute

AI Engineer · Eigenständige Produktion

Selbstständig · Hof / Saale, DE

- Acht produktive KI-Systeme End-to-End entworfen, deployt und betrieben — eigene Architektur, eigener Code, eigene Infrastruktur.
- Orchestra gebaut, einen Open-Source-Multi-Agenten-KI-Workspace (TypeScript/Next.js 15): MoA-Pipeline mit parallelen Experten-Proposern, code-garantiertem Skeptiker, Embedding-basierter Disagreement Detection — 2.602 Tests, 74 Post-Mortems, CI.
- Multi-Provider-LLM-Pipelines (OpenAI, Gemini, Groq, Ollama) mit Failover; strukturierte Outputs; Voice- + Vision-Flows.
- Edge-Serverless auf Cloudflare Workers; Telegram-Mini-App- + Bot-Integration mit HMAC-SHA256-Webhook-Verifikation.
- Self-hosted Infrastruktur: Ubuntu VPS, Nginx, systemd, Docker, Tailscale, NVIDIA Container Toolkit.
- Monetarisierung: Telegram-Stars-Zahlungen, atomare Kredit-Operationen, Referral-Logik, Anti-Fraud-Heuristiken.

2023 — 2025

Selbststudium · KI & Automatisierung

Eigenständig

- n8n-Agent-Workflows; Prompt Engineering; strukturierte Outputs; Chain-of-Thought-Architekturen.
- Lokales LLM-Deployment (Ollama, llama.cpp, faster-whisper); Docker Compose; SSE-Streaming.
- Cloudflare Workers, Apps Script, Firebase, FastAPI, systemd, Edge-First-Architekturen.
- Parallel Teilzeit in der Logistik gearbeitet, um das Abend- und Wochenendstudium zu finanzieren.

10/2022 — 10/2023

Frontend-Entwickler (Umschulung)

Tel-Ran Berlin · 960 Std. · DEKRA-zertifiziert

- JavaScript Advanced (ESM, async, Prototypen); React-Grundlagen; Datenstrukturen & Algorithmen; HTML5/CSS3.
 - DevOps-Grundlagen (Git/GitHub, CI, Docker-Basics); QA; UI/UX-Grundlagen.
 - Berufswechsel aus der Logistik in die Softwareentwicklung.
-

2008 – 2022

Logistik & Fernverkehr

Tesco Carlisle (UK) · internationaler Güterverkehr, UK & Europa

- 14 Jahre in multikulturellen Teams in UK, DE, NL, FR, BE.
- Warehouse-Management-Systeme (WMS), Planogramme, Routenplanung, Just-in-Time-Lieferung.
- Prozessdisziplin und Belastbarkeit unter Termindruck — die Fähigkeit, die sich überträgt.

§ 04 Stack — *im Produktionseinsatz*

Agenten-Systeme

Mixture-of-Agents-(MoA)-Orchestrierung · dynamische Persona-Generierung · Embedding-basierte Disagreement Detection · Reflexionsschleifen (Generator-Critic-Revisor) · Kosten-Telemetrie · Agent-Tool-Design · Sandbox- & SSRF-Guards

AI / LLM

OpenAI GPT-4 / 4.1 / TTS · Google Gemini 2.5 · Groq Whisper-large-v3 · Ollama (LLaMA, Gemma) · faster-whisper · whisper.cpp · OpenRouter · Nemotron · multi-provider failover · structured outputs · prompt engineering · RAG-ready patterns

Automation

n8n · workflows · agents · code nodes (JS/Python) · webhook routing · error handling & retries · chain-of-thought architecture · multi-protocol agents

Programmierung

TypeScript (strict) · Next.js 15 / React · JavaScript (ESM, async) · Python (FastAPI, Flask) · Bash · HTML5 · CSS3 · SQL · Streaming-APIs (SSE)

Cloud / Edge

Cloudflare Workers · Wrangler · Google Apps Script · Firebase Realtime DB · GitHub Pages · Supabase / PostgreSQL

Betrieb

Docker / Compose · Nginx (Reverse Proxy, TLS) · Ubuntu VPS · systemd (Services, Timer) · Health Checks · Auto-Restart · Log-Rotation · NVIDIA Container Toolkit · Tailscale

Sicherheit

HMAC-SHA256 · JWT · Telegram Bot API · Telegram-Mini-Apps-SDK · Telegram-Stars-Zahlungen · CSP · CORS · Webhook-Verifikation · Rate Limiting · Secrets-Management ·

Tooling

Git / GitHub · GitHub Actions CI · Vite · Vitest · Playwright · ESLint · Wrangler · macOS / Linux daily driver

§ 05 Ausbildung & Sprachen

Frontend-Webentwickler

10/2022 – 10/2023 · 960 Unterrichtsstunden

Tel-Ran Berlin · DEKRA-zertifizierte Vollzeit-Umschulung. JavaScript Advanced, React, Datenstrukturen & Algorithmen, DevOps, QA, UI/UX, HTML5/CSS3.

Zertifikat: DEKRA Nr. 2023337
Ausgestellt: Berlin – 2023

Sprachen

Russisch		Muttersprache
Lettisch		C2 · fließend
Englisch		C1 · Business
Deutsch		B1