

# Aleksejs Buss

AI ENGINEER · MULTI-AGENTEN-SYSTEME

*Schöpfer von Orchestra — Open-Source-Mixture-of-Agents-Plattform.  
Acht Produktionssysteme. Solo ausgeliefert.*

|          |                                               |
|----------|-----------------------------------------------|
| E-MAIL   | <i>aleksbuss@gmail.com</i>                    |
| GITHUB   | <i>github.com/aleksbuss</i>                   |
| WEB      | <i>aleksejs-portfolio.pages.dev</i>           |
| STANDORT | <i>Hof / Saale, DE · EU-Bürger</i>            |
| STATUS   | <i>Sofort verfügbar · remote oder vor Ort</i> |

---

## § 01 Profil — *auf einen Blick*

---

AI Engineer mit Schwerpunkt *Multi-Agenten-LLM-Systeme*. Schöpfer von **Orchestra** — einem Open-Source-Mixture-of-Agents-Workspace (TypeScript / Next.js 15) mit **2.602 Tests und 74 dokumentierten Post-Mortems**: parallele Experten-Agenten, ein code-garantierter Skeptiker, Embedding-basierte Disagreement Detection. Seit Mitte 2025 habe ich **acht produktive KI-Systeme** mit echten Nutzern ausgeliefert — Cloudflare Workers (Edge), Telegram Mini-Apps, Multi-Provider-LLM-Pipelines, Zahlungssysteme, Security. Features von der Spezifikation bis zur Live-Infrastruktur, End-to-End — unternehmerische Verantwortung in einer Person.

05/2026 — heute

FLAGGSCHIFF · OSS

### Orchestra — *Multi-Agenten-KI-Workspace*

*Mixture-of-Agents-Pipeline · code-garantierter Skeptiker · Live-Kosten-Telemetrie.*

Self-hosted KI-Workspace, der bei jeder substanziellen Anfrage 3–5 spezialisierte Experten-Agenten parallel ausführt. Router mit dynamischer Persona-Generierung; ein Skeptiker, der per Code — nicht per Prompt — garantiert ist; Embedding-basierte Disagreement Detection, die Expertenkonflikte sichtbar macht statt sie zu glätten; Reflexions-Kritiker + Revisor-Pass. Live-Kostenanzeige (Tokens + USD) pro Chat. BYOK oder vollständig lokal via Ollama. 2.602 Tests, 74 dokumentierte Post-Mortems, CI — MIT-lizenziert.

Router (DPG) → proposers | Skeptic → disagreement detector → Aggregator → reflection

[github.com/aleksbuss/orchestra](https://github.com/aleksbuss/orchestra) →

Stack: TypeScript (strict) · Next.js 15 · Vitest · Playwright · Docker

---

08/2025 — heute

PRODUKTION

### AI Dictaphone *v7.0*

*Edge-Voice-Pipeline · Whisper → LLM · Sub-Sekunden-Latenz.*

Serverlose Voice-to-Insight-Pipeline auf Cloudflare Edge. Sprachnachricht → Groq-Whisper-Transkription → LLaMA-3.3-70B-Zusammenfassung → Mini-App-UI. Null Cold-Start, HMAC-verifizierte Webhooks, keine dauerhafte Speicherung von Sprachinhalten.

Telegram Mini-App → Cloudflare Workers → Groq Whisper+LLaMA 3.3 70B

Stack: Cloudflare Workers · Groq Whisper-large-v3 · LLaMA 3.3 70B · JS ESM

---

09/2025 — heute

## AI Moderation *Bot*

*n8n-Workflow · Dual-KI-Failover · Auto-Eskalation.*

Eine n8n-Pipeline mit 15+ Knoten klassifiziert jede Telegram-Nachricht mit strukturierten JSON-Outputs, leitet zur Aktion weiter und eskaliert Sanktionen über drei Stufen. Dual-Provider-Failover (Nemotron primär, GPT-4.1 als Fallback) hält die Moderation am Laufen, wenn eine LLM-API ausfällt.

Message → Nemotron → fallback GPT-4.1 → Router → action

Stack: n8n · OpenRouter · GPT-4.1-mini · Nemotron · Telegram Bot API

---

10/2025 — heute

SAAS-PRODUKT

## AI Psychology *Bot*

*Komplettes SaaS · Zahlungen · Krisenhilfe · CBT-Übungen.*

End-to-End-SaaS solo: HMAC-SHA256-Auth → verteiltes Apps-Script-Backend → Firebase Realtime DB → Gemini-2.5- + TTS-Pipeline. Telegram Stars als nativer Checkout, atomare Kredit-Operationen, Referral-Programm, Panik-Intervention, 7-Skill-Protokoll.

Mini-App → HMAC-SHA256 → Apps Script → Firebase → Gemini+TTS

Stack: Gemini 2.5 · Telegram Stars · Firebase RTDB · Apps Script · HMAC-SHA256

---

02/2025 — heute

BUSHMARK.CC

## Bushmark — *Secure Clipboard*

*Self-hosted · Cookie-Auth · 1-Klick-Installation.*

Selbst gehostete sichere Zwischenablage auf bushmark.cc — drei persistente Slots, 24h-Verlauf, Auto-Rotation, Tailwind-UI. Ein-Zeilen-Bash-Installation auf jedem Ubuntu-VPS richtet Nginx + FastAPI + systemd automatisch ein.

Browser → Nginx reverse proxy → FastAPI (systemd)

**bushmark.cc** → Stack: FastAPI · Nginx · systemd · Tailwind · Ubuntu 24.04

---

11/2025 – heute

SELF-HOSTED

## CyberDed Ultra + ComfyUI

*Lokale KI-Infrastruktur · 1-Klick-Installer · Android + Linux.*

Bash-Installer für den gesamten Local-AI-Stack: Ollama für Inferenz, ComfyUI für Bildgenerierung, automatische NVIDIA-Container-Toolkit-Konfiguration, Flask-Backend mit Server-Sent-Events-Streaming-Chat, Echtzeit-Monitoring. Zwei Zielsysteme — Linux + Termux Android.

Bash installer → Ollama+ComfyUI Docker → Flask SSE

[github.com/aleksbuss](https://github.com/aleksbuss) → Stack: Docker · Ollama · Flask · ComfyUI · NVIDIA Container Toolkit

---

01/2026 – heute

OPEN SOURCE

## Termux AI Dictaphone

*Android als Offline-KI-Server · null Cloud-Kosten.*

Komplette Offline-KI auf jedem modernen Android: Whisper-Transkription via faster-whisper / whisper.cpp, LLaMA-/Gemma-Inferenz via Ollama — alles on-device über Termux. Null API-Kosten, volle Privatsphäre. Als Open Source veröffentlicht.

Termux (Android) → faster-whisper → Ollama (LLaMA, Gemma)

[github.com/aleksbuss](https://github.com/aleksbuss) → Stack: Termux · faster-whisper · whisper.cpp · Ollama · Python

07/2025 — heute

## AI Engineer · Eigenständige Produktion

Selbstständig · Hof / Saale, DE

- Acht produktive KI-Systeme End-to-End entworfen, deployt und betrieben — eigene Architektur, eigener Code, eigene Infrastruktur.
  - Orchestra gebaut, einen Open-Source-Multi-Agenten-KI-Workspace (TypeScript/Next.js 15): MoA-Pipeline mit parallelen Experten-Proposern, code-garantiertem Skeptiker, Embedding-basierter Disagreement Detection — 2.602 Tests, 74 Post-Mortems, CI.
  - Multi-Provider-LLM-Pipelines (OpenAI, Gemini, Groq, Ollama) mit Failover; strukturierte Outputs; Voice- + Vision-Flows.
  - Edge-Serverless auf Cloudflare Workers; Telegram-Mini-App- + Bot-Integration mit HMAC-SHA256-Webhook-Verifikation.
  - Self-hosted Infrastruktur: Ubuntu VPS, Nginx, systemd, Docker, Tailscale, NVIDIA Container Toolkit.
  - Monetarisierung: Telegram-Stars-Zahlungen, atomare Kredit-Operationen, Referral-Logik, Anti-Fraud-Heuristiken.
- 

2023 — 2025

## Selbststudium · KI & Automatisierung

Eigenständig

- n8n-Agent-Workflows; Prompt Engineering; strukturierte Outputs; Chain-of-Thought-Architekturen.
  - Lokales LLM-Deployment (Ollama, llama.cpp, faster-whisper); Docker Compose; SSE-Streaming.
  - Cloudflare Workers, Apps Script, Firebase, FastAPI, systemd, Edge-First-Architekturen.
  - Parallel Teilzeit in der Logistik gearbeitet, um das Abend- und Wochenendstudium zu finanzieren.
- 

10/2022 — 10/2023

## Frontend-Entwickler (Umschulung)

Tel-Ran Berlin · 960 Std. · DEKRA-zertifiziert

- JavaScript Advanced (ESM, async, Prototypen); React-Grundlagen; Datenstrukturen & Algorithmen; HTML5/CSS3.
  - DevOps-Grundlagen (Git/GitHub, CI, Docker-Basics); QA; UI/UX-Grundlagen.
  - Berufswechsel aus der Logistik in die Softwareentwicklung.
-

2008 – 2022

## Logistik & Fernverkehr

Tesco Carlisle (UK) · internationaler Güterverkehr, UK & Europa

- 14 Jahre in multikulturellen Teams in UK, DE, NL, FR, BE.
- Warehouse-Management-Systeme (WMS), Planogramme, Routenplanung, Just-in-Time-Lieferung.
- Prozessdisziplin und Belastbarkeit unter Termindruck — die Fähigkeit, die sich überträgt.

## § 04 Stack — *im Produktionseinsatz*

---

### Agenten-Systeme

Mixture-of-Agents-(MoA)-Orchestrierung · dynamische Persona-Generierung · Embedding-basierte Disagreement Detection · Reflexionsschleifen (Generator-Critic-Revisor) · Kosten-Telemetrie · Agent-Tool-Design · Sandbox- & SSRF-Guards

---

### AI / LLM

OpenAI GPT-4 / 4.1 / TTS · Google Gemini 2.5 · Groq Whisper-large-v3 · Ollama (LLaMA, Gemma) · faster-whisper · whisper.cpp · OpenRouter · Nemotron · multi-provider failover · structured outputs · prompt engineering · RAG-ready patterns

---

### Automation

n8n · workflows · agents · code nodes (JS/Python) · webhook routing · error handling & retries · chain-of-thought architecture · multi-protocol agents

---

### Programmierung

TypeScript (strict) · Next.js 15 / React · JavaScript (ESM, async) · Python (FastAPI, Flask) · Bash · HTML5 · CSS3 · SQL · Streaming-APIs (SSE)

---

### Cloud / Edge

Cloudflare Workers · Wrangler · Google Apps Script · Firebase Realtime DB · GitHub Pages · Supabase / PostgreSQL

---

### Betrieb

Docker / Compose · Nginx (Reverse Proxy, TLS) · Ubuntu VPS · systemd (Services, Timer) · Health Checks · Auto-Restart · Log-Rotation · NVIDIA Container Toolkit · Tailscale

---

### Sicherheit

HMAC-SHA256 · JWT · Telegram Bot API · Telegram-Mini-Apps-SDK · Telegram-Stars-Zahlungen · CSP · CORS · Webhook-Verifikation · Rate Limiting · Secrets-Management ·

Tooling

Git / GitHub · GitHub Actions CI · Vite · Vitest · Playwright · ESLint · Wrangler · macOS / Linux daily driver

§ 05 Ausbildung & Sprachen

Frontend-Webentwickler

10/2022 – 10/2023 · 960 Unterrichtsstunden

Tel-Ran Berlin · DEKRA-zertifizierte Vollzeit-Umschulung. JavaScript Advanced, React, Datenstrukturen & Algorithmen, DevOps, QA, UI/UX, HTML5/CSS3.

Zertifikat: DEKRA Nr. 2023337  
Ausgestellt: Berlin – 2023

Sprachen

|          |             |               |
|----------|-------------|---------------|
| Russisch | <div></div> | Muttersprache |
| Lettisch | <div></div> | C2 · fließend |
| Englisch | <div></div> | C1 · Business |
| Deutsch  | <div></div> | B1            |